ACTIVIDAD 5 · VISUALIZACIÓN DE DATOS

Agrupamiento K-Means con el conjunto de datos Iris

Seis pares de características, k = 2 a 5, inercia, silueta y comparación con las especies

Reporte técnico · Elaborado con Python 3 (pandas, NumPy, scikit-learn, matplotlib)

Alumna	Alondra Goretti González Martínez
Código	218534681
Profesor	Emilio Barajas González
Actividad	Actividad 5 — K-Means (100 puntos)
Fecha de entrega	2 de noviembre, 7:00
Conjunto de datos	Iris (Fisher, 1936) · 150 observaciones · 5 atributos

Resumen. Este reporte documenta la aplicación del algoritmo K-means al conjunto de datos Iris usando cada uno de los seis pares únicos de características, sin emplear la especie para entrenar. Para cada par se probaron k = 2, 3, 4 y 5 con las variables estandarizadas, y se registraron la inercia, el coeficiente de silueta, los centroides y la asignación de cada flor. Los resultados se comparan con el método del codo y con las especies reales mediante el índice de Rand ajustado. El par formado por la longitud y el ancho del pétalo produjo la agrupación más clara (k = 3, silueta de 0.674 y ARI de 0.886).

Contenido

1. Introducción y objetivos 3

2. Sustento teórico 4

2.1 El algoritmo K-means 4

2.2 Estandarización 4

2.3 Inercia y método del codo 4

2.4 Coeficiente de silueta 4

2.5 Índice de Rand ajustado 4

3. Metodología: pasos de la práctica 5

4. Resultados y análisis 6

4.1 Visualización general de los datos 6

4.2 Inercia y silueta por par y por k 7

4.3 Parecido con las especies reales 8

4.4 Método del codo y coeficiente de silueta 8

4.5 Gráficas de los grupos 10

4.6 Centroides y asignación de los grupos 13

4.7 Valor de k elegido para cada par 15

4.8 Discusión integrada 15

5. Conclusión general 16

Anexo A. Código de la práctica 17

Anexo B. Base de datos completa 19

Anexo C. Cómo ejecutar el proyecto y publicarlo en GitHub 21

Referencias 21

1. Introducción y objetivos

El análisis de agrupamiento (*clustering*) busca organizar observaciones en grupos de modo que las de un mismo grupo se parezcan entre sí más que a las de otros grupos, sin conocer de antemano una etiqueta. K-means es uno de los algoritmos de agrupamiento más utilizados por su sencillez (Lloyd, 1982; MacQueen, 1967). Su resultado depende de dos decisiones del analista: qué características se usan y cuántos grupos (k) se piden, por lo que conviene estudiar cómo cambian los grupos al variar ambas.

El conjunto de datos Iris fue publicado por Fisher (1936) a partir de las mediciones de Anderson (1935) en flores de tres especies del género *Iris*. Contiene 150 flores, 50 por especie, descritas por cuatro medidas en centímetros. Es un caso didáctico clásico porque una especie (Setosa) está separada de las otras dos y estas últimas (Versicolor y Virginica) se traslapan parcialmente, lo que permite evaluar si un algoritmo no supervisado recupera la estructura real.

Objetivo general. Aplicar K-means a Iris con pares de características, analizar cómo cambian los grupos al modificar k y determinar qué pares permiten distinguir mejor las agrupaciones.

Objetivos específicos.

- Ejecutar K-means con los seis pares únicos de características y k = 2, 3, 4 y 5, con el mismo procedimiento en todos los casos.
- Registrar inercia, coeficiente de silueta, centroides y grupo asignado a cada flor, y graficar los grupos.
- Comparar los resultados mediante tablas, el método del codo y la silueta, y elegir un valor de k para cada par.
- Contrastar los grupos con las especies reales sin usarlas para entrenar, e interpretar la influencia de las características y de k.

2. Sustento teórico

2.1 El algoritmo K-means

K-means divide *n* observaciones en *k* grupos representados por sus centroides (la media de las observaciones del grupo). El procedimiento es: (a) elegir k centroides iniciales (en scikit-learn, con k-means++, que reparte los centros iniciales; Arthur y Vassilvitskii, 2007); (b) asignar cada observación al centroide más cercano según la distancia euclidiana; (c) recalcular cada centroide como la media de las observaciones asignadas; y (d) repetir (b) y (c) hasta que las asignaciones dejen de cambiar. Como el resultado depende de los centroides iniciales, se ejecuta varias veces (aquí 10) y se conserva la mejor solución.

2.2 Estandarización

K-means usa distancias, por lo que una variable con valores numéricamente mayores dominaría a otra. La estandarización (puntaje z) transforma cada variable como z = (x − media) / desviación estándar, de modo que ambas tengan media 0 y desviación 1 y pesen igual.

2.3 Inercia y método del codo

La inercia es la suma de las distancias al cuadrado entre cada observación y el centroide de su grupo; mide qué tan compactos son los grupos. Siempre disminuye al aumentar k (con k = n valdría cero), así que no basta para elegir k. El método del codo grafica la inercia contra k y busca el punto donde la mejora deja de ser grande.

2.4 Coeficiente de silueta

Para cada observación, *a* es la distancia media a las de su propio grupo y *b* la distancia media al grupo vecino más cercano; su silueta es s = (b − a) / máx(a, b). El promedio, entre −1 y 1, resume qué tan compactos y separados están los grupos: valores altos indican grupos bien definidos (Rousseeuw, 1987).

2.5 Índice de Rand ajustado

El índice de Rand ajustado (ARI; Hubert y Arabie, 1985) compara dos particiones: vale 1 si coinciden, cerca de 0 si el acuerdo es el esperable por azar. No depende de los nombres de los grupos, por lo que es adecuado para comparar con las especies, ya que las etiquetas 0, 1, 2… que asigna K-means son arbitrarias.

3. Metodología: pasos de la práctica

La práctica se realizó en Python 3 con un flujo reproducible: el script `kmeans_iris.py` (Anexo A) lee `iris.csv`, ejecuta los 24 análisis (6 pares × 4 valores de k), guarda las tablas en `resultados/` y las figuras en `figs/`.

Paso 0. Preparar el entorno

Instalar las bibliotecas.

```
pip install pandas numpy scikit-learn matplotlib
```

Paso 1. Cargar la base de datos

Leer el archivo y revisar columnas, registros y datos faltantes.

```
df = pd.read_csv("iris.csv")
print(df.shape, df.isna().sum().sum())
```

Paso 2. Formar los seis pares

Combinar las cuatro variables de dos en dos, sin repetir pares.

```
pares = list(itertools.combinations(VARS, 2))
```

Paso 3. Estandarizar

Seleccionar las dos columnas del par y aplicar puntaje z. La especie no se incluye.

```
X = StandardScaler().fit_transform(df[[a, b]])
```

Paso 4. Aplicar K-means

Probar k = 2, 3, 4 y 5 con los mismos parámetros en todos los pares.

```
km = KMeans(n_clusters=k, n_init=10, random_state=42).fit(X)
```

Paso 5. Registrar métricas

Guardar inercia, silueta, centroides (en cm) y grupo de cada flor.

```
km.inertia_; silhouette_score(X, km.labels_); km.cluster_centers_
```

Paso 6. Graficar

Dibujar los grupos con las dos mediciones como ejes, la curva del codo y la matriz de silueta.

```
plt.scatter(df[a], df[b], c=km.labels_)
```

Paso 7. Comparar con la especie

Solo después de agrupar, calcular el ARI frente a la especie real.

```
adjusted_rand_score(df["variety"], km.labels_)
```

Paso 8. Reproducir y publicar

Ejecutar el script y publicar la página interactiva en GitHub Pages (Anexo C).

```
python kmeans_iris.py
```

4. Resultados y análisis

4.1 Visualización general de los datos

La base contiene 150 observaciones y 5 atributos: cuatro variables numéricas continuas en centímetros y la especie (categórica nominal). Las clases están balanceadas (50 flores por especie), no hay datos faltantes y existe un único registro repetido (filas 102 y 143, de Virginica), que se conservó por pertenecer a la base original. La Tabla 1 resume las variables y la Figura 1 muestra los seis planos de características con la especie real, únicamente como referencia.

Tabla 1

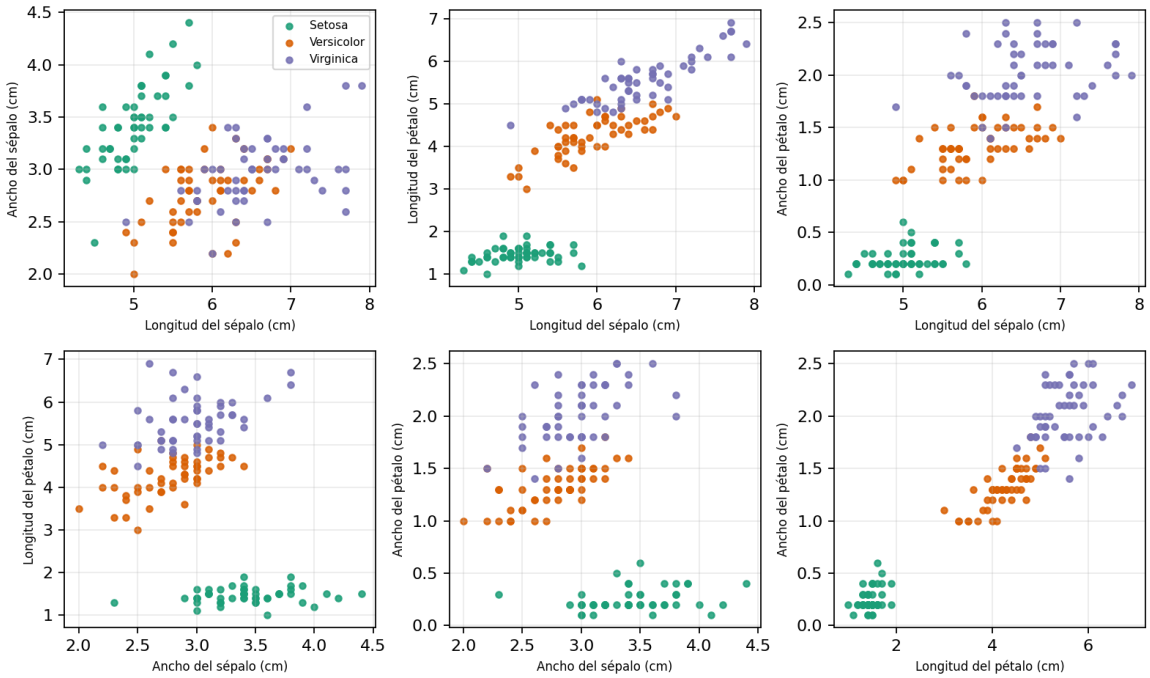
Estadísticos descriptivos de las variables de Iris

Variable	Media	Desv. est.	Mínimo	Máximo
Longitud del sépalo (cm)	5.843	0.828	4.3	7.9
Ancho del sépalo (cm)	3.057	0.436	2.0	4.4
Longitud del pétalo (cm)	3.758	1.765	1.0	6.9
Ancho del pétalo (cm)	1.199	0.762	0.1	2.5

Nota. n = 150. Desviación estándar muestral (n − 1).

Figura 1

Los seis planos de características de Iris coloreados por especie real



Nota. La especie se muestra solo como referencia; no se usó para entrenar K-means. Elaboración propia con Python.

En los planos que incluyen una variable del pétalo, Setosa forma un grupo compacto y aislado y Versicolor y Virginica ocupan regiones contiguas con un pequeño traslape; en el plano de las dos variables del sépalo, las tres nubes se mezclan. Esta lectura anticipa qué pares deberían agrupar mejor.

4.2 Inercia y silueta por par y por k

La Tabla 2 compara los seis pares y los cuatro valores de k. Como se esperaba, la inercia baja en todos los pares al aumentar k. La silueta, en cambio, es mayor con k = 2 en los seis pares y disminuye de forma general al subir k.

Tabla 2

Inercia y coeficiente de silueta (inercia / silueta) por par de características y número de grupos

Par	k = 2	k = 3	k = 4	k = 5
SL–SW	166.95 / 0.448	102.62 / 0.439	79.77 / 0.408	61.81 / 0.401
SL–PL	84.72 / 0.632	43.03 / 0.545	28.49 / 0.547	22.40 / 0.504
SL–PW	94.03 / 0.572	51.14 / 0.509	38.61 / 0.468	30.21 / 0.483
SW–PL	116.66 / 0.592	75.15 / 0.477	55.11 / 0.453	41.35 / 0.417
SW–PW	125.37 / 0.564	79.23 / 0.462	59.18 / 0.440	42.90 / 0.430
PL–PW	54.17 / 0.743	18.03 / 0.674	12.28 / 0.599	9.15 / 0.574

Nota. SL = longitud del sépalo, SW = ancho del sépalo, PL = longitud del pétalo, PW = ancho del pétalo. Variables estandarizadas; k-means con n_init = 10 y random_state = 42.

El par PL–PW presenta la silueta más alta con cada k (0.743, 0.674, 0.599 y 0.574) y la inercia más baja (54.17, 18.03, 12.28 y 9.15), por lo que sus grupos son los más compactos y separados. SL–SW es el más débil, con silueta máxima de 0.448.

4.3 Parecido con las especies reales

Solo después de agrupar se calculó el ARI frente a la especie (Tabla 3). Con PL–PW y k = 3 el ARI alcanza 0.886, muy por encima del resto de las combinaciones (máximo 0.605). Con k = 4 y k = 5 el ARI de PL–PW baja a 0.756 y 0.664: los grupos adicionales subdividen las nubes en lugar de acercarse a las especies.

Tabla 3

Índice de Rand ajustado entre los grupos de K-means y las especies reales

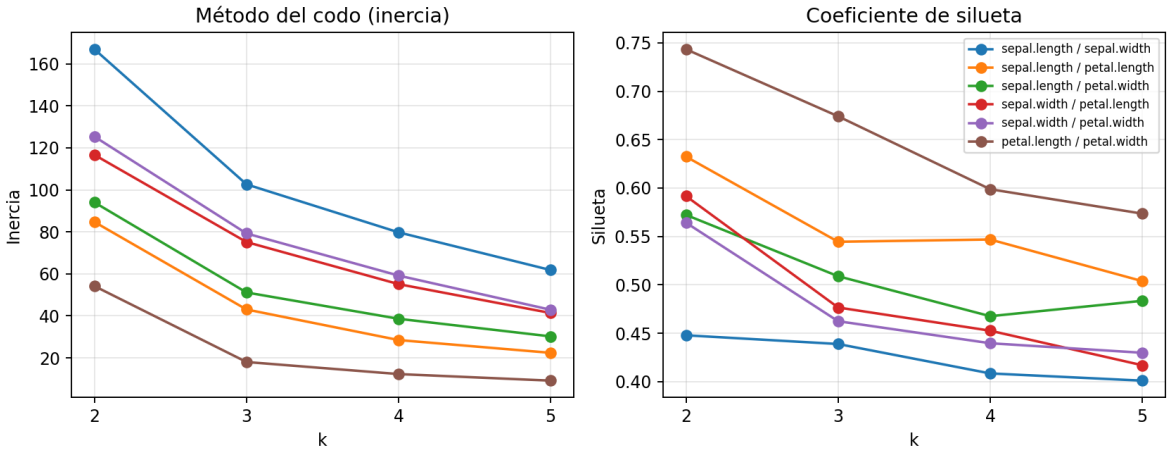
Par	k = 2	k = 3	k = 4	k = 5
SL–SW	0.534	0.519	0.399	0.392
SL–PL	0.511	0.563	0.537	0.539
SL–PW	0.467	0.605	0.587	0.584
SW–PL	0.544	0.539	0.412	0.371
SW–PW	0.544	0.591	0.465	0.394
PL–PW	0.568	0.886	0.756	0.664

Nota. ARI = 1 indica coincidencia perfecta; valores cercanos a 0, acuerdo esperable por azar.

4.4 Método del codo y coeficiente de silueta

Figura 2

Inercia (método del codo) y coeficiente de silueta para los seis pares y k = 2 a 5

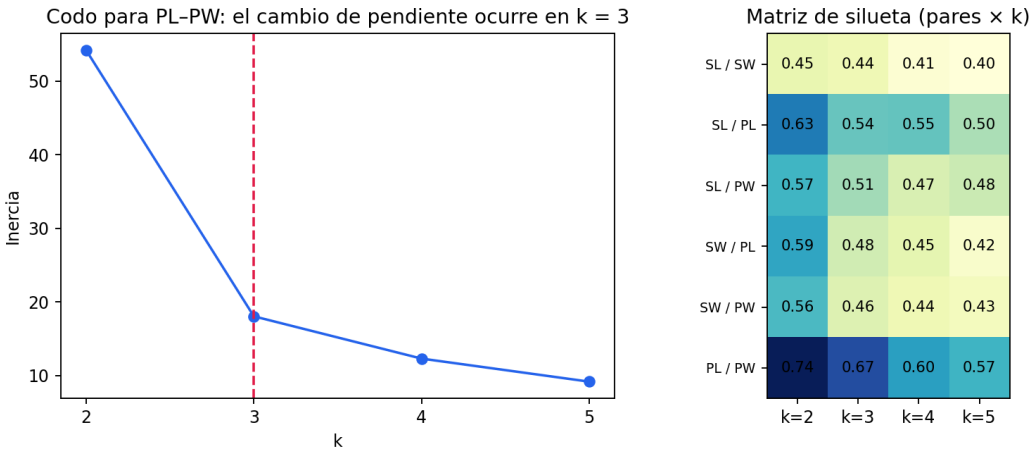


Nota. Elaboración propia con Python.

Las curvas de inercia (Figura 2, izquierda) son monótonas decrecientes, como corresponde. En PL–PW la caída de k = 2 a k = 3 es muy marcada (de 54.17 a 18.03) y después se suaviza (12.28 y 9.15): el codo se ubica en k = 3 (Figura 3, izquierda). Las curvas de silueta (Figura 2, derecha) muestran que PL–PW se mantiene por encima del resto en todos los k.

Figura 3

Codo del par PL–PW (izquierda) y matriz de silueta de los seis pares (derecha)



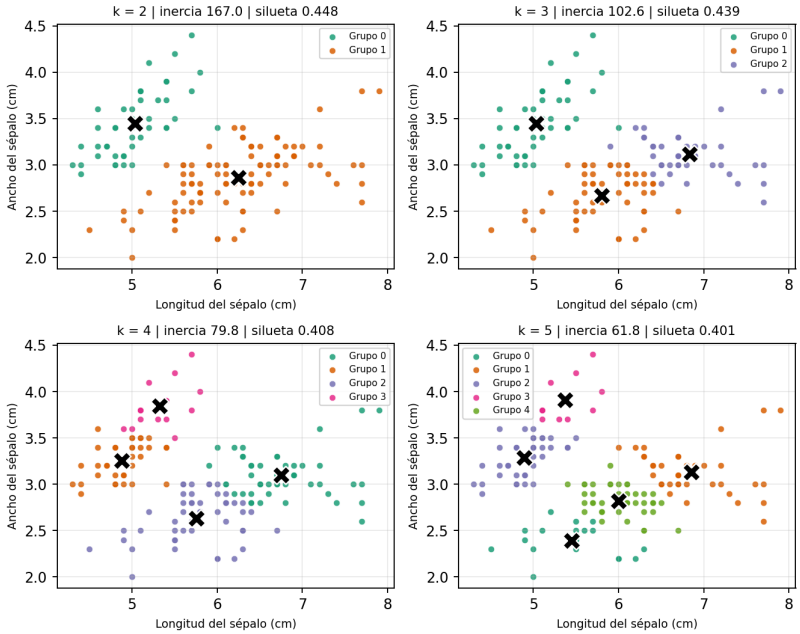
Nota. En la matriz, los tonos más oscuros indican grupos mejor definidos. Elaboración propia con Python.

4.5 Gráficas de los grupos

Las Figuras 4 a 9 muestran, para cada par, los grupos con k = 2, 3, 4 y 5. Las flores se colorean por grupo y los centroides se marcan con una X negra; los ejes son las dos mediciones originales en centímetros.

Figura 4

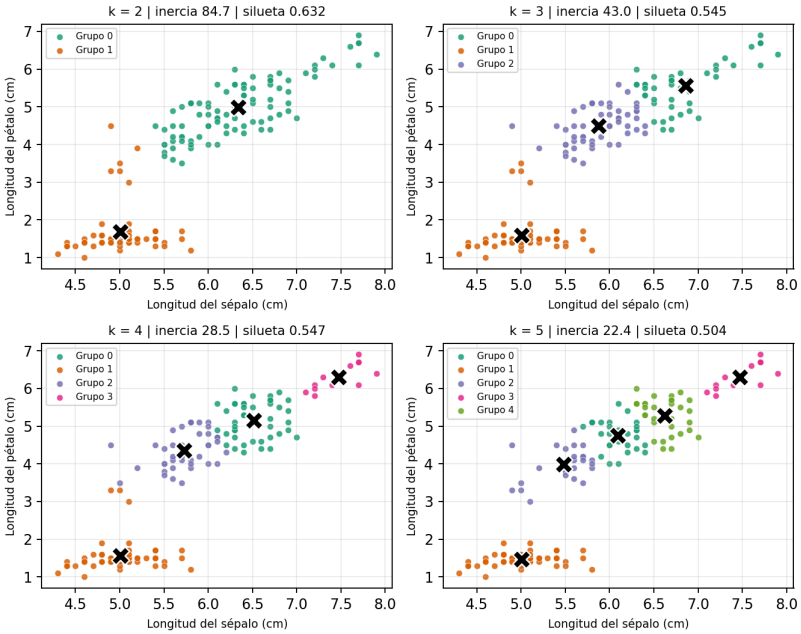
Grupos de K-means para SL–SW (longitud del sépalo y ancho del sépalo) con k = 2, 3, 4 y 5



Nota. Cada panel indica la inercia y la silueta. Las X negras son los centroides. Elaboración propia con Python.

Figura 5

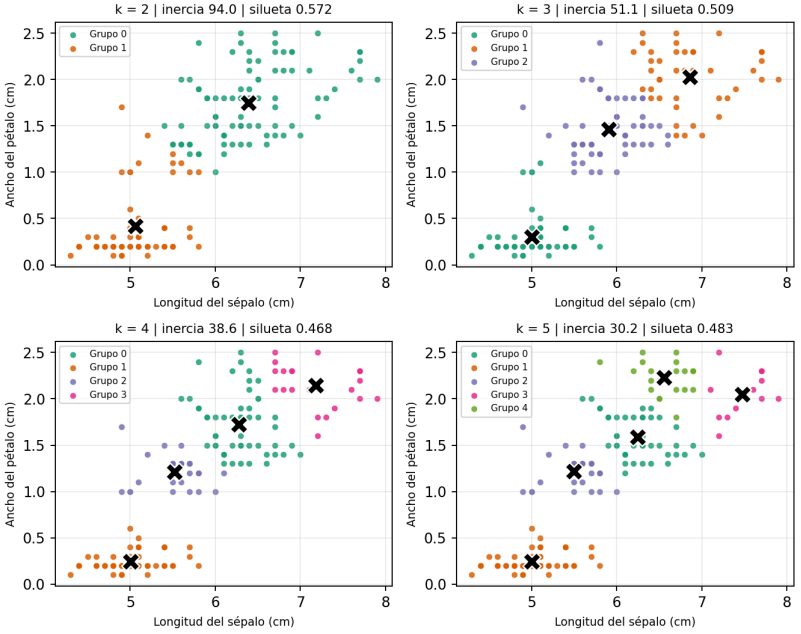
Grupos de K-means para SL–PL (longitud del sépalo y longitud del pétalo) con k = 2, 3, 4 y 5



Nota. Cada panel indica la inercia y la silueta. Las X negras son los centroides. Elaboración propia con Python.

Figura 6

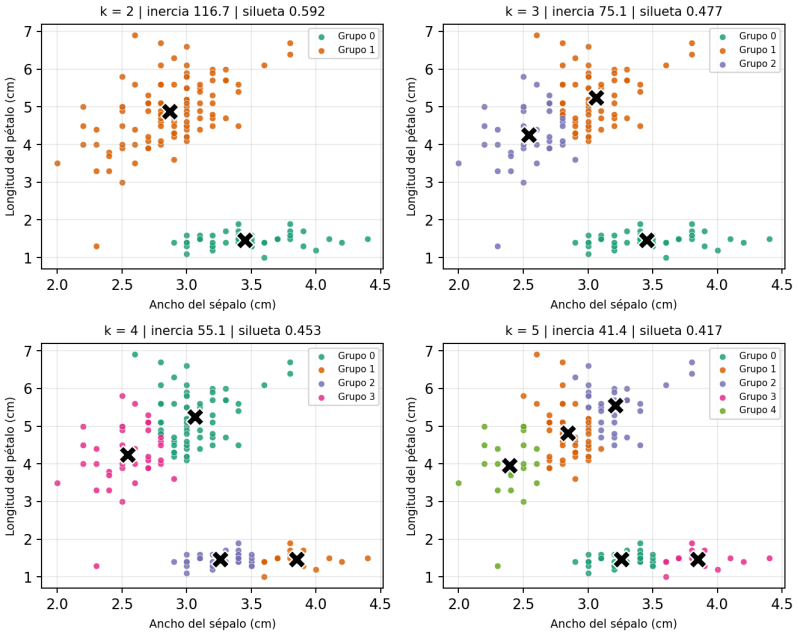
Grupos de K-means para SL–PW (longitud del sépalo y ancho del pétalo) con k = 2, 3, 4 y 5



Nota. Cada panel indica la inercia y la silueta. Las X negras son los centroides. Elaboración propia con Python.

Figura 7

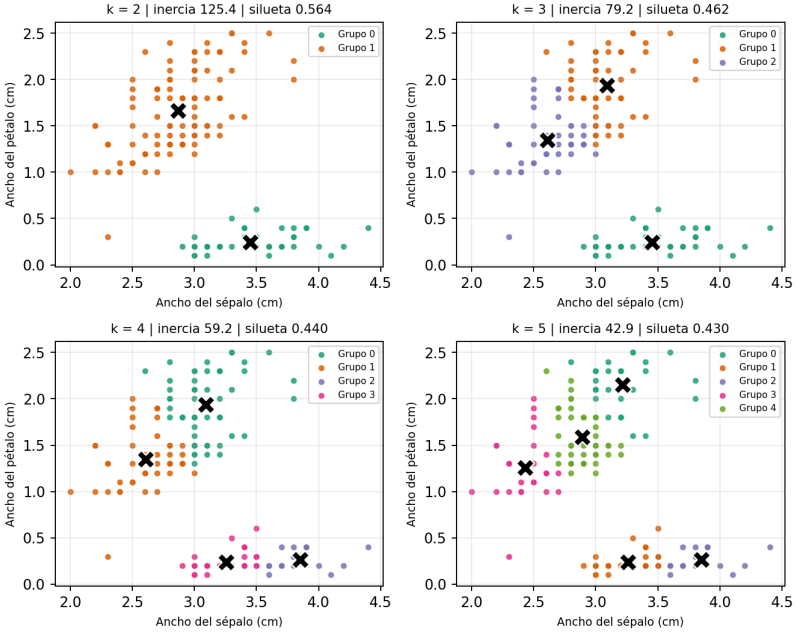
Grupos de K-means para SW–PL (ancho del sépalo y longitud del pétalo) con k = 2, 3, 4 y 5



Nota. Cada panel indica la inercia y la silueta. Las X negras son los centroides. Elaboración propia con Python.

Figura 8

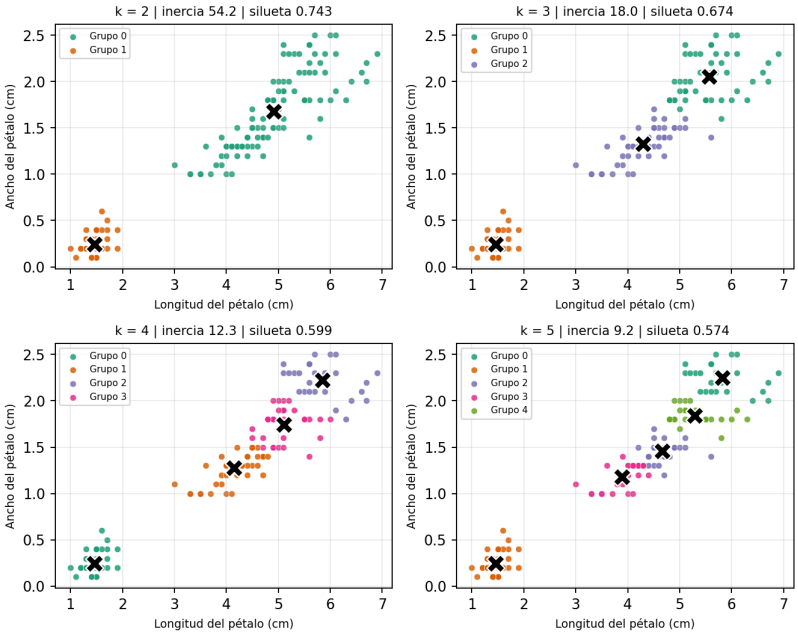
Grupos de K-means para SW–PW (ancho del sépalo y ancho del pétalo) con k = 2, 3, 4 y 5



Nota. Cada panel indica la inercia y la silueta. Las X negras son los centroides. Elaboración propia con Python.

Figura 9

Grupos de K-means para PL–PW (longitud del pétalo y ancho del pétalo) con k = 2, 3, 4 y 5



Nota. Cada panel indica la inercia y la silueta. Las X negras son los centroides. Elaboración propia con Python.

En PL–PW (Figura 4) el grupo de Setosa aparece aislado ya desde k = 2, y con k = 3 la nube restante se parte en dos grupos de tamaño parecido, que se corresponden con Versicolor y Virginica salvo en la zona de contacto. En los pares con sépalo (Figuras 7 y 9, entre otras) las fronteras entre grupos cortan nubes continuas sin un hueco natural, lo que explica sus siluetas bajas.

4.6 Centroides y asignación de los grupos

Las Tablas 4 a 9 muestran, con el k elegido para cada par, los centroides en centímetros y cuántas flores de cada especie quedaron en cada grupo. La asignación individual de las 150 flores para cada par y cada k está en `resultados/asignaciones.csv`.

Tabla 4

Centroides y composición por especie de los grupos de SL–SW con k = 2

Grupo	Longitud del sépalo (cm)	Ancho del sépalo (cm)	n	Setosa	Versicolor	Virginica
0	5.04	3.45	50	49	1	0
1	6.25	2.86	100	1	49	50

Nota. Los centroides están en centímetros. Las columnas de especie cuentan flores; las etiquetas de grupo son arbitrarias.

Tabla 5

Centroides y composición por especie de los grupos de SL–PL con k = 3

Grupo	Longitud del sépalo (cm)	Longitud del pétalo (cm)	n	Setosa	Versicolor	Virginica
0	6.86	5.57	43	0	9	34
1	5.01	1.60	54	50	4	0
2	5.87	4.49	53	0	37	16

Nota. Los centroides están en centímetros. Las columnas de especie cuentan flores; las etiquetas de grupo son arbitrarias.

Tabla 6

Centroides y composición por especie de los grupos de SL–PW con k = 3

Grupo	Longitud del sépalo (cm)	Ancho del pétalo (cm)	n	Setosa	Versicolor	Virginica
0	5.01	0.30	54	50	4	0
1	6.86	2.03	41	0	6	35
2	5.91	1.46	55	0	40	15

Nota. Los centroides están en centímetros. Las columnas de especie cuentan flores; las etiquetas de grupo son arbitrarias.

Tabla 7

Centroides y composición por especie de los grupos de SW–PL con k = 2

Grupo	Ancho del sépalo (cm)	Longitud del pétalo (cm)	n	Setosa	Versicolor	Virginica
0	3.45	1.47	49	49	0	0
1	2.87	4.87	101	1	50	50

Nota. Los centroides están en centímetros. Las columnas de especie cuentan flores; las etiquetas de grupo son arbitrarias.

Tabla 8

Centroides y composición por especie de los grupos de SW–PW con k = 3

Grupo	Ancho del sépalo (cm)	Ancho del pétalo (cm)	n	Setosa	Versicolor	Virginica
0	3.45	0.24	49	49	0	0
1	3.09	1.94	54	0	15	39
2	2.61	1.35	47	1	35	11

Nota. Los centroides están en centímetros. Las columnas de especie cuentan flores; las etiquetas de grupo son arbitrarias.

Tabla 9

Centroides y composición por especie de los grupos de PL–PW con k = 3

Grupo	Longitud del pétalo (cm)	Ancho del pétalo (cm)	n	Setosa	Versicolor	Virginica
0	5.57	2.06	48	0	2	46
1	1.46	0.25	50	50	0	0
2	4.30	1.32	52	0	48	4

Nota. Los centroides están en centímetros. Las columnas de especie cuentan flores; las etiquetas de grupo son arbitrarias.

4.7 Valor de k elegido para cada par

La silueta favorece k = 2 en todos los pares porque solo existe una separación nítida (Setosa frente a las otras dos). Para elegir k se combinaron el codo, la silueta y el ARI (Tabla 10): se eligió k = 3 cuando el tercer grupo mejora el parecido con las especies sin una caída fuerte de la silueta, y k = 2 cuando el tercer grupo no aporta.

Tabla 10

Valor de k elegido y justificación para cada par

Par	k elegido	Justificación
PL–PW	3	Codo claro en k = 3; ARI de 0.886
SL–PL	3	ARI de 0.563 frente a 0.511 con k = 2; silueta aceptable (0.545)
SL–PW	3	Mejor ARI entre los pares mixtos (0.605)
SW–PW	3	ARI de 0.591, mejora respecto de k = 2 (0.544)
SW–PL	2	El tercer grupo no mejora (ARI de 0.539) y la silueta baja de 0.592 a 0.477
SL–SW	2	Ningún k produce grupos definidos; silueta máxima de 0.448

4.8 Discusión integrada

Par con la agrupación más clara. PL–PW (longitud y ancho del pétalo) es el mejor en todas las métricas, de acuerdo con la exploración de la Actividad 3, donde el pétalo separaba casi por completo las especies.

Pares con mayor superposición. SL–SW mezcla las tres especies (silueta máxima de 0.448). SW–PL y SW–PW mejoran porque incluyen una variable del pétalo, pero el ancho del sépalo aporta poca separación.

Efecto de cambiar k. Aumentar k siempre redujo la inercia, pero no mejoró la utilidad de los grupos: con k = 4 y 5 se obtuvieron subgrupos más pequeños que no corresponden a especies, y la silueta y el ARI disminuyeron en la mayoría de los pares.

¿Se parecen a las especies? Solo PL–PW con k = 3 se parece claramente a las especies (ARI de 0.886). En el resto el parecido es parcial (ARI entre 0.37 y 0.61). K-means no conoce las especies: solo busca grupos compactos con las dos medidas, por lo que puede mezclar Versicolor y Virginica donde sus nubes se tocan.

5. Conclusión general

La selección de características fue el factor más influyente: con las dos medidas del pétalo K-means recuperó casi perfectamente las especies, mientras que con las dos del sépalo no logró separarlas. El número de grupos actuó de otra manera: aumentar k siempre bajó la inercia, pero más allá de k = 3 solo fragmentó las nubes sin aportar grupos más útiles. Conviene elegir k combinando el método del codo, la silueta y el conocimiento del problema, y usar las etiquetas reales solo como validación posterior. Finalmente, la estandarización es necesaria para que ambas variables influyan por igual en las distancias.

Como limitaciones, los resultados son descriptivos y se obtuvieron con solo dos variables por análisis; K-means supone grupos compactos y de forma aproximadamente esférica, y depende de la inicialización (por eso se fijó la semilla y se usó n_init = 10).

Anexo A. Código de la práctica

Script completo (`kmeans_iris.py`). Con `iris.csv` en la misma carpeta, genera todas las tablas y figuras del reporte.

```
"""Actividad 5 - K-Means sobre Iris con pares de características.
Uso:  python kmeans_iris.py   (requiere iris.csv en la misma carpeta)
Genera: resultados/metricas.csv, resultados/centroides.csv, resultados/asignaciones.csv
        figs/ (gráficas de grupos, codo, silueta, matriz comparativa)
"""
import os, itertools
import numpy as np, pandas as pd
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score, adjusted_rand_score

VARS = ["sepal.length", "sepal.width", "petal.length", "petal.width"]
ES = {"sepal.length": "Longitud del sépalo (cm)", "sepal.width": "Ancho del sépalo (cm)",
      "petal.length": "Longitud del pétalo (cm)", "petal.width": "Ancho del pétalo (cm)"}
KS = [2, 3, 4, 5]
SEED = 42

df = pd.read_csv("iris.csv")
print(df.shape); print(df.isna().sum().sum(), "datos faltantes"); print(df.describe().round(3))
os.makedirs("resultados", exist_ok=True); os.makedirs("figs", exist_ok=True)

pares = list(itertools.combinations(VARS, 2))   # 6 pares únicos
met, cen, asg = [], [], []
modelos = {}
for a, b in pares:
    X = StandardScaler().fit_transform(df[[a, b]])          # estandarización (z-score)
    sc = StandardScaler().fit(df[[a, b]])
    for k in KS:
        km = KMeans(n_clusters=k, n_init=10, random_state=SEED).fit(X)
        sil = silhouette_score(X, km.labels_)
        ari = adjusted_rand_score(df["variety"], km.labels_)  # solo para comparar, no para entrenar
        met.append(dict(par=f"{a} / {b}", k=k, inercia=km.inertia_, silueta=sil, ARI_vs_especie=ari))
        orig = sc.inverse_transform(km.cluster_centers_)
        for g in range(k):
            cen.append(dict(par=f"{a} / {b}", k=k, grupo=g, **{a: orig[g, 0], b: orig[g, 1]},
                            n_flores=int((km.labels_ == g).sum())))
        for i, l in enumerate(km.labels_):
            asg.append(dict(par=f"{a} / {b}", k=k, flor=i + 1, grupo=int(l), especie=df.variety[i]))
        modelos[(a, b, k)] = (km, sc)

M = pd.DataFrame(met); M.to_csv("resultados/metricas.csv", index=False)
pd.DataFrame(cen).to_csv("resultados/centroides.csv", index=False)
pd.DataFrame(asg).to_csv("resultados/asignaciones.csv", index=False)
print(M.round(3).to_string(index=False))

# Mejor k por silueta (entre 2 y 5) para cada par
mejor = M.loc[M.groupby("par").silueta.idxmax()][["par", "k", "silueta", "ARI_vs_especie"]]
print("\nMejor k por silueta:\n", mejor.round(3).to_string(index=False))

COL = ["#1b9e77", "#d95f02", "#7570b3", "#e7298a", "#66a61e"]
# Gráficas de grupos: una figura por par, 4 paneles (k = 2..5)
for a, b in pares:
    fig, ax = plt.subplots(1, 4, figsize=(15, 3.6))
    for p, k in zip(ax, KS):
        km, sc = modelos[(a, b, k)]
        for g in range(k):
            m = km.labels_ == g
            p.scatter(df[a][m], df[b][m], s=20, color=COL[g], alpha=.8, edgecolor="white", linewidth=.3)
        c = sc.inverse_transform(km.cluster_centers_)
        p.scatter(c[:, 0], c[:, 1], marker="X", s=150, color="k", edgecolor="white", zorder=5)
```

```
        r = M[(M.par == f"{a} / {b}") & (M.k == k)].iloc[0]
        p.set_title(f"k = {k}  |  silueta {r.silueta:.3f}", fontsize=10)
        p.set_xlabel(ES[a], fontsize=8); p.set_ylabel(ES[b], fontsize=8)
    fig.tight_layout(); fig.savefig(f"figs/grupos_{a}_{b}.png", dpi=150); plt.close(fig)

# Codo y silueta (6 curvas)
fig, ax = plt.subplots(1, 2, figsize=(11, 4))
for par, g in M.groupby("par", sort=False):
    ax[0].plot(g.k, g.inercia, marker="o", label=par); ax[1].plot(g.k, g.silueta, marker="o", label=par)
ax[0].set_title("Método del codo (inercia)"); ax[0].set_xlabel("k"); ax[0].set_ylabel("Inercia")
ax[1].set_title("Coeficiente de silueta"); ax[1].set_xlabel("k"); ax[1].set_ylabel("Silueta")
for p in ax: p.set_xticks(KS); p.grid(alpha=.3)
ax[1].legend(fontsize=7); fig.tight_layout(); fig.savefig("figs/codo_silueta.png", dpi=150); plt.close(fig)

# Matriz comparativa (pares x k) de silueta
piv = M.pivot(index="par", columns="k", values="silueta").loc[M.par.unique()]
fig, a = plt.subplots(figsize=(6, 3.6))
im = a.imshow(piv.values, cmap="YlGnBu"); a.set_xticks(range(len(KS)), [f"k={k}" for k in KS])
a.set_yticks(range(len(piv)), piv.index, fontsize=8)
for i in range(piv.shape[0]):
    for j in range(piv.shape[1]): a.text(j, i, f"{piv.values[i, j]:.2f}", ha="center", va="center", fontsize=9)
fig.colorbar(im, label="Silueta"); fig.tight_layout(); fig.savefig("figs/matriz_silueta.png", dpi=150); plt.close(fig)
```

Anexo B. Base de datos completa

Los 150 registros de Iris (Set = Setosa, Ver = Versicolor, Vir = Virginica; medidas en cm). SL = longitud del sépalo, SW = ancho del sépalo, PL = longitud del pétalo, PW = ancho del pétalo.

#	SL	SW	PL	PW	Esp.	#	SL	SW	PL	PW	Esp.	#	SL	SW	PL	PW	Esp.
1	5.1	3.5	1.4	0.2	Set	51	7.0	3.2	4.7	1.4	Ver	101	6.3	3.3	6.0	2.5	Vir
2	4.9	3.0	1.4	0.2	Set	52	6.4	3.2	4.5	1.5	Ver	102	5.8	2.7	5.1	1.9	Vir
3	4.7	3.2	1.3	0.2	Set	53	6.9	3.1	4.9	1.5	Ver	103	7.1	3.0	5.9	2.1	Vir
4	4.6	3.1	1.5	0.2	Set	54	5.5	2.3	4.0	1.3	Ver	104	6.3	2.9	5.6	1.8	Vir
5	5.0	3.6	1.4	0.2	Set	55	6.5	2.8	4.6	1.5	Ver	105	6.5	3.0	5.8	2.2	Vir
6	5.4	3.9	1.7	0.4	Set	56	5.7	2.8	4.5	1.3	Ver	106	7.6	3.0	6.6	2.1	Vir
7	4.6	3.4	1.4	0.3	Set	57	6.3	3.3	4.7	1.6	Ver	107	4.9	2.5	4.5	1.7	Vir
8	5.0	3.4	1.5	0.2	Set	58	4.9	2.4	3.3	1.0	Ver	108	7.3	2.9	6.3	1.8	Vir
9	4.4	2.9	1.4	0.2	Set	59	6.6	2.9	4.6	1.3	Ver	109	6.7	2.5	5.8	1.8	Vir
10	4.9	3.1	1.5	0.1	Set	60	5.2	2.7	3.9	1.4	Ver	110	7.2	3.6	6.1	2.5	Vir
11	5.4	3.7	1.5	0.2	Set	61	5.0	2.0	3.5	1.0	Ver	111	6.5	3.2	5.1	2.0	Vir
12	4.8	3.4	1.6	0.2	Set	62	5.9	3.0	4.2	1.5	Ver	112	6.4	2.7	5.3	1.9	Vir
13	4.8	3.0	1.4	0.1	Set	63	6.0	2.2	4.0	1.0	Ver	113	6.8	3.0	5.5	2.1	Vir
14	4.3	3.0	1.1	0.1	Set	64	6.1	2.9	4.7	1.4	Ver	114	5.7	2.5	5.0	2.0	Vir
15	5.8	4.0	1.2	0.2	Set	65	5.6	2.9	3.6	1.3	Ver	115	5.8	2.8	5.1	2.4	Vir
16	5.7	4.4	1.5	0.4	Set	66	6.7	3.1	4.4	1.4	Ver	116	6.4	3.2	5.3	2.3	Vir
17	5.4	3.9	1.3	0.4	Set	67	5.6	3.0	4.5	1.5	Ver	117	6.5	3.0	5.5	1.8	Vir
18	5.1	3.5	1.4	0.3	Set	68	5.8	2.7	4.1	1.0	Ver	118	7.7	3.8	6.7	2.2	Vir
19	5.7	3.8	1.7	0.3	Set	69	6.2	2.2	4.5	1.5	Ver	119	7.7	2.6	6.9	2.3	Vir
20	5.1	3.8	1.5	0.3	Set	70	5.6	2.5	3.9	1.1	Ver	120	6.0	2.2	5.0	1.5	Vir
21	5.4	3.4	1.7	0.2	Set	71	5.9	3.2	4.8	1.8	Ver	121	6.9	3.2	5.7	2.3	Vir
22	5.1	3.7	1.5	0.4	Set	72	6.1	2.8	4.0	1.3	Ver	122	5.6	2.8	4.9	2.0	Vir
23	4.6	3.6	1.0	0.2	Set	73	6.3	2.5	4.9	1.5	Ver	123	7.7	2.8	6.7	2.0	Vir
24	5.1	3.3	1.7	0.5	Set	74	6.1	2.8	4.7	1.2	Ver	124	6.3	2.7	4.9	1.8	Vir
25	4.8	3.4	1.9	0.2	Set	75	6.4	2.9	4.3	1.3	Ver	125	6.7	3.3	5.7	2.1	Vir
26	5.0	3.0	1.6	0.2	Set	76	6.6	3.0	4.4	1.4	Ver	126	7.2	3.2	6.0	1.8	Vir
27	5.0	3.4	1.6	0.4	Set	77	6.8	2.8	4.8	1.4	Ver	127	6.2	2.8	4.8	1.8	Vir
28	5.2	3.5	1.5	0.2	Set	78	6.7	3.0	5.0	1.7	Ver	128	6.1	3.0	4.9	1.8	Vir
29	5.2	3.4	1.4	0.2	Set	79	6.0	2.9	4.5	1.5	Ver	129	6.4	2.8	5.6	2.1	Vir

#	SL	SW	PL	PW	Esp.	#	SL	SW	PL	PW	Esp.	#	SL	SW	PL	PW	Esp.
30	4.7	3.2	1.6	0.2	Set	80	5.7	2.6	3.5	1.0	Ver	130	7.2	3.0	5.8	1.6	Vir
31	4.8	3.1	1.6	0.2	Set	81	5.5	2.4	3.8	1.1	Ver	131	7.4	2.8	6.1	1.9	Vir
32	5.4	3.4	1.5	0.4	Set	82	5.5	2.4	3.7	1.0	Ver	132	7.9	3.8	6.4	2.0	Vir
33	5.2	4.1	1.5	0.1	Set	83	5.8	2.7	3.9	1.2	Ver	133	6.4	2.8	5.6	2.2	Vir
34	5.5	4.2	1.4	0.2	Set	84	6.0	2.7	5.1	1.6	Ver	134	6.3	2.8	5.1	1.5	Vir
35	4.9	3.1	1.5	0.2	Set	85	5.4	3.0	4.5	1.5	Ver	135	6.1	2.6	5.6	1.4	Vir
36	5.0	3.2	1.2	0.2	Set	86	6.0	3.4	4.5	1.6	Ver	136	7.7	3.0	6.1	2.3	Vir
37	5.5	3.5	1.3	0.2	Set	87	6.7	3.1	4.7	1.5	Ver	137	6.3	3.4	5.6	2.4	Vir
38	4.9	3.6	1.4	0.1	Set	88	6.3	2.3	4.4	1.3	Ver	138	6.4	3.1	5.5	1.8	Vir
39	4.4	3.0	1.3	0.2	Set	89	5.6	3.0	4.1	1.3	Ver	139	6.0	3.0	4.8	1.8	Vir
40	5.1	3.4	1.5	0.2	Set	90	5.5	2.5	4.0	1.3	Ver	140	6.9	3.1	5.4	2.1	Vir
41	5.0	3.5	1.3	0.3	Set	91	5.5	2.6	4.4	1.2	Ver	141	6.7	3.1	5.6	2.4	Vir
42	4.5	2.3	1.3	0.3	Set	92	6.1	3.0	4.6	1.4	Ver	142	6.9	3.1	5.1	2.3	Vir
43	4.4	3.2	1.3	0.2	Set	93	5.8	2.6	4.0	1.2	Ver	143	5.8	2.7	5.1	1.9	Vir
44	5.0	3.5	1.6	0.6	Set	94	5.0	2.3	3.3	1.0	Ver	144	6.8	3.2	5.9	2.3	Vir
45	5.1	3.8	1.9	0.4	Set	95	5.6	2.7	4.2	1.3	Ver	145	6.7	3.3	5.7	2.5	Vir
46	4.8	3.0	1.4	0.3	Set	96	5.7	3.0	4.2	1.2	Ver	146	6.7	3.0	5.2	2.3	Vir
47	5.1	3.8	1.6	0.2	Set	97	5.7	2.9	4.2	1.3	Ver	147	6.3	2.5	5.0	1.9	Vir
48	4.6	3.2	1.4	0.2	Set	98	6.2	2.9	4.3	1.3	Ver	148	6.5	3.0	5.2	2.0	Vir
49	5.3	3.7	1.5	0.2	Set	99	5.1	2.5	3.0	1.1	Ver	149	6.2	3.4	5.4	2.3	Vir
50	5.0	3.3	1.4	0.2	Set	100	5.7	2.8	4.1	1.3	Ver	150	5.9	3.0	5.1	1.8	Vir

Anexo C. Cómo ejecutar el proyecto y publicarlo en GitHub

El proyecto se entrega como un repositorio completo (carpeta `actividad5_kmeans_github`). Contiene la página interactiva (`index.html`), el código, la base de datos, los resultados, las figuras y los informes en PDF.

Ejecución local

```
pip install -r requirements.txt
python kmeans_iris.py
```

Publicación en GitHub Pages

- Crear un repositorio nuevo en GitHub (por ejemplo, `kmeans-iris`) y subir todo el contenido de la carpeta.
- En *Settings* → *Pages*, elegir *Deploy from a branch*, rama `main` y carpeta `/ (root)`.
- Después de uno o dos minutos la página queda disponible en `https://USUARIO.github.io/kmeans-iris/`.

Ejecución automática en GitHub Actions

El archivo `.github/workflows/kmeans.yml` instala las dependencias, ejecuta `kmeans_iris.py` en cada *push* y guarda las tablas y figuras como artefactos descargables, de modo que el análisis en Python también se reproduce en GitHub.

Referencias

Anderson, E. (1935). The irises of the Gaspé Peninsula. *Bulletin of the American Iris Society, 59*, 2–5.

Arthur, D., y Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, 1027–1035.

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics, 7*(2), 179–188. https://doi.org/10.1111/j.1469-1809.1936.tb02137.x

Hubert, L., y Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory, 28*(2), 129–137. https://doi.org/10.1109/TIT.1982.1056489

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics*

and Probability, 1, 281–297.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7